Installation eines RAG-Systems mit n8n, Ollama und Qdrant

Autor: Michael Schrot
Tutorial: YOUTUBE.COM/@MSCHROT

Systemvoraussetzungen

Komponente	Empfehlung
Betriebssystem	Windows 10 / 11
Prozessor	Ryzen 7 (oder vergleichbar)
Arbeitsspeicher	32 GB RAM
Virtualisierung	VMware® Workstation 17 Pro (Build 17.6.4-24832109)
Gast-OS	Ubuntu Server 24.04.4 LTS
VM-Ressourcen	2 CPUs mit je 4 Kernen, 8 GB RAM, 20 GB Festplatte
Netzwerk	Bridge-Modus

1. Ubuntu Server mit Docker & Portainer installieren

Folge der Anleitung:
https://github.com/mschrot/n8n

Ziel: Ubuntu Server mit Docker und Portainer als Container-Management-Oberfläche einrichten.

2. Stack in Portainer bereitstellen

Erstelle in Portainer einen neuen Stack und füge folgende `docker-compose.yml` ein:

```yaml
version: "3.8"

services:
  n8n:
    image: n8nio/n8n:latest
    container_name: n8n
    ports:
      - "5678:5678"
    environment:
      - N8N_SECURE_COOKIE=false
      - N8N_HOST=0.0.0.0
      - N8N_PORT=5678
      - N8N_PROTOCOL=http
      - WEBHOOK_URL=http://DEINE_IP:5678/
      - GENERIC_TIMEZONE=Europe/Berlin
    volumes:
      - n8n_data:/home/node/.n8n
    restart: always

  ollama:
    image: ollama/ollama
    container_name: ollama
    ports:
      - "11434:11434"
    volumes:
      - ollama_data:/root/.ollama
    restart: always

  qdrant:
    image: qdrant/qdrant
    container_name: qdrant
    ports:
      - "6333:6333"
    volumes:
      - qdrant_data:/qdrant/storage
    restart: always

volumes:
  n8n_data:
  ollama_data:
  qdrant_data:
```

> **Wichtig:** Ersetze `DEINE_IP` in der Umgebungsvariable `WEBHOOK_URL` durch die tatsächliche IP-Adresse deines Ubuntu-Servers.

Nach dem Deployment sind folgende Dienste erreichbar:

Dienst	URL
n8n	`http://DEINE_IP:5678`
Ollama API	`http://DEINE_IP:11434`
Qdrant API	`http://DEINE_IP:6333`

3. Zugriff per SSH

Verwende ein SSH-Tool wie **MobaXterm** oder **PuTTY**, um dich mit deinem Ubuntu-Server zu verbinden.

```bash
ssh benutzername@DEINE_IP
```

Nach der Anmeldung kannst du Docker-Container direkt verwalten.

4. Ollama-Modelle installieren

Logge dich in den laufenden Ollama-Container ein:

```bash
docker exec -it ollama bash
```

Lade die benötigten Modelle herunter:

```bash
ollama pull mistral
ollama pull nomic-embed-text
```

Prüfe die installierten Modelle:

```bash
ollama list
```

Beispielausgabe:

```text
NAME                       ID              SIZE      MODIFIED
nomic-embed-text:latest    0a10f422b7d7    274 MB    24 seconds ago
mistral:latest             6577803aa9a0    4.4 GB    21 minutes ago
```

Verlasse den Container mit `exit`.

5. n8n Workflow importieren

1. Öffne deinen Browser und rufe n8n auf:
   `http://DEINE_IP:5678`
2. Erstelle ein neues Benutzerkonto (bei erstmaligem Aufruf).
3. Erstelle einen neuen Workflow.
4. Importiere die bereitgestellte Workflow-Datei:
   `n8n_rag_build.json`
5. Passe in den entsprechenden Knoten folgende Endpunkte an:

- Ollama: `http://ollama:11434`
- Qdrant: `http://qdrant:6333`

> **Hinweis:** Da alle Dienste im selben Docker-Netzwerk laufen, können die Container-Namen als Hostnamen verwendet werden.